Business Intelligence

Proyecto final · Entrega 1

Diagnóstico, estrategia y diseño

Diagnóstico Estratégico y Rediseño de Arquitectura BI para MoviBogotá S.A.

Integrante	Código
David Santiago Prieto Beltrán	506212024
Naren Santiago Rojas Sánchez	506232716
Joseph David Vargas Olaya	506232072

Dato	Valor
Docente	Leandro Pájaro Fuentes
Fecha de entrega	23/10/2026
Repositorio	https://github.com/Narens-dev/bi-proyecto-equipo506232716

Resumen de la entrega

Este proyecto expone el diagnóstico analítico y la propuesta de arquitectura BI para MoviBogotá S.A., operador de transporte masivo que padece una *arqu*itectura accidental debido a la dispersión de datos operativos, transaccionales y de mantenimiento. Tras evaluar la organización en el modelo BIMM (Modelo de madurez de Inteligencia de Negocios), se diagnostica en Fase 1 (No existe BI) con objetivo de escalar a Fase 4 (Data Warehouse) mediante el proyecto. Se diseña un modelo dimensional en estrella centrado en la transacción de validación de pasajeros y viajes, cuya granularidad corresponde a un registro por validación de pasaje en una estación/paradero, ruta y minuto específico.

1. Caso de negocio

En la actualidad, la Gerencia de Operaciones y Planeación del Servicio enfrenta un cuello de botella crítico para la gestión estratégica y operacional. El entorno urbano de Bogotá presenta una alta variabilidad condicionada por congestiones viales con fallas en su planificación, o directamente, ni siquiera planificadas. Por otro lado, obras de infraestructura, eventos meteorológicos adversos (lluvias intensas o altas temperaturas por el actual fenómeno del niño) y cambios drásticas en los flujos de pasajeros según la franja horaria y el día de la semana. A pesar de generar diariamente millones de registros de datos a través de sus validadores de pasajes, sensores GPS en los vehículos y registros de mantenimiento en taller, la organización es incapaz de consolidar esta información para tomar decisiones oportunas.

Específicamente, la decisión de negocio central que la Gerente de Operaciones hoy no puede tomar es: ¿Cómo programar y redistribuir de forma dinámica la flota de buses y las frecuencias de despacho por ruta e intervalos por horas, minimizando los costos de distancia recorrida en vacío, y los tiempos de espera de los usuarios en estaciones de alta demanda? La dificultad para responder a esta pregunta clave obedece a que la información operativa reside en silos de datos inconexos y administrados por diferentes áreas bajo una arquitectura accidental.

Por un lado, la dirección de Recaudo maneja los registros de validación de pasajes mediante archivos planos sacados del sistema central de molinetes. Además, el área de Control de Flota monitorea los recorridos y tiempos de paso a través de una API de telemetría GPS, mientras que la dirección de Mantenimiento registra las novedades técnicas en hojas de cálculo distribuidas de Excel. Debido a esta fragmentación, cuando la Gerencia intenta evaluar el rendimiento de una ruta o justificar el incremento de buses de refuerzos en horas pico, el equipo de analistas debe realizar cruces manuales de grandes volúmenes de datos mediante macros complejas y tablas dinámicas.

Este proceso tarda habitualmente entre tres y cinco días laborables, lo que implica que las decisiones operativas se toman con base en intuiciones o información rezagada que ya no refleja la realidad de la movilidad en la ciudad. Como consecuencia directa, MoviBogotá S.A. padece sanciones económicas por incumplimiento de frecuencias, sobrecostos por desgaste prematuro de la flota y un deterioro continuo en la satisfacción del usuario final.

Ante este panorama, la implementación de una solución integral de Inteligencia de Negocios (BI) se convierte en una prioridad estratégica. La construcción de una arquitectura de datos moderna y centralizada permitirá unificar las fuentes heterogéneas, depurar algunas inconsistencias de calidad históricas y estructurar un almacén de datos diseñado específicamente para el análisis multidimensional.

A través de esta transformación analítica, MoviBogotá S.A. logrará expandir el acceso a la información operativa mediante tableros de control interactivos y modelos analíticos avanzados. Esto dará facultad a la Gerencia de Operaciones para prever cuellos de botella en la demanda, monitorear la salud técnica del parque automotor en tiempo real y reaccionar proactivamente ante imprevistos, transitando de un modelo reactivo e intuitivo a una cultura organizacional basada en datos confiables, eficientes y alineados con las exigencias del transporte urbano moderno

MoviBogotá S.A. es un operador privado del sistema de transporte masivo urbano en Bogotá, responsable de la gestión, mantenimiento y operación de una flota conformada por aproximadamente 2.300 y 2.500 buses articulados y biarticulados, así como de la cobertura operacional de más de 80 rutas troncales e interconectoras en la ciudad. En el marco de un contrato de concesión pública, la empresa debe garantizar altos estándares de regularidad, frecuencia, puntualidad y seguridad, al tiempo que busca optimizar la eficiencia financiera de la operación y el uso del parque automotor.

1.1 Organización y contexto

MoviBogotá S.A. es una organización perteneciente al sector de Movilidad y Transporte Masivo Urbano en Bogotá. Se clasifica como una empresa de tamaño mediano-grande, contando con una planta de más de 1.200 empleados (distribuidos entre conductores, personal técnico de taller, controladores de patio y personal administrativo) y administrando un parque automotor superior a los 450 buses articulados y biarticulados.

La operación se encuentra centralizada en la ciudad de Bogotá D.C. y se gestiona operativamente desde tres patios taller principales (Patio Suba, Patio Américas y Patio Usme), cubriendo una red operacional de más de 80 rutas troncales e interconectoras.

El decisor de negocio principal para este caso es la Gerente de Operaciones y Planeación del Servicio. La decisión crítica de negocio que no puede tomar hoy es la reprogramación y asignación dinámica de la flota y sus frecuencias de despacho por franja horaria, ruta e imprevistos operativos, basada en métricas integradas de rentabilidad por kilómetro, niveles de ocupación real y el estado técnico-mecánico de los buses.

1.2 Síntomas de arquitectura accidental

#	Síntoma	Evidencia en el caso	Capa afectada
S1	Fechas y horas heterogéneas entre sistemas	El sistema de torniquetes registra marcas temporales en formato YYYY/DD/MM HH:MI/SS, mientras que los reportes de mantenimiento usan DD/MM/YYYY registros GPS usan marca de tiempo Unix.	Fuentes / Integración
S2	Discrepancia en códigos de estaciones y paraderos	La tabla de validaciones usan códigos alfanuméricos (EST-010), el archivo de mantenimiento usa nombres informales (EST. Calle 72) y las alertas de tráfico usan coordenadas relativas.	Integración / Almacén
S3	Silos de información e informes mensuales en Excel	La gerencia consolidaba la ocupación mensual cruzando manualmente archivos .xlsx y .csv de más de 100.000 filas congelando los computadores y generando cifras contradictorias entre Operaciones y Finanzas.	Almacén / Usuario final

1.3 Preguntas de negocio

#	Pregunta	Tipo (BI, BA o Big Data)	Por qué es de ese tipo
P0	¿Qué rutas y estaciones registran mayor pérdida de margen operacional y de congestión por franja horaria y mes durante los últimos 2 años	BI	Describe lo ocurrido combinando datos históricos estructurados de validaciones, costos operacionales y frecuencias
P1	¿Cuál es el volumen diario de pasajeros transportados agrupado por el tipo de tarifa (general, adulto mayor, mujer embarazada, Sisbén) y estación?	BI	Analiza métricas acumuladas e históricas con dimensiones de tiempo, usuario y ubicación
P2	¿Cómo afectan los incidentes viales y las condiciones de clima el cumplimiento de la frecuencia programada por ruta?	BA	Identifica patrones de correlación entre variables externas (clima/tráfico) y el desempeño operativo para diagnóstico analítico
P3	¿Cuáles buses representan una mayor probabilidad de fallas técnicas según sus kilómetros recorridos y su frecuencia de uso en rutas de alta demanda?	BA	Aplicar análisis predictivo e inferencial sobre el histórico de mantenimiento y uso del parque automotor

2. Inventario de fuentes

A continuación, se listan y caracterizan las fuentes de datos heterogéneas seleccionadas para la solución de Business Intelligence, especificando su procedencia, formato, volumen histórico y los principales problemas de calidad detectados.

2.1 Fuentes

Fuente	Procedencia (URL)	Formato	Registros	Periodo	Fecha de descarga	Licencia
F1	https://github.com/Narens-dev/bi-proyecto-equipo506232716/blob/main/datos/raw/Dataset_registros.csv	CSV	55.000	Ene 2024 - Dic 2025	20/10/26	- Uso público institucional - Datos sintéticos
F2	https://www.datos.gov.co/browse?q=transporte%20masivo%20bogota	CSV	12.500	Ene 2024 – Dic 2025	20/10/26	Creative Commons Attribution 4.0 (CC BY 4.0)

Fuente	Procedencia (URL)	Formato	Registros	Periodo	Fecha de descarga	Licencia
F3	https://datos.movilidadbogota.gov.co	JSON	8.400	Ene 2024 – Dic 2025	20/10/26	Open Database License

2.2 Problemas de calidad detectados

Fuente	Campo	Problema	Ejemplo real del dato
F1	Fecha_hora	Formatos de fecha heterogéneos y múltiples separadores temporales combinados (estándar ISO, formato de 12 horas con AM/PM y marcas Epoch en texto)	"*2024-04-01 14:52:00*" frente a "*25/03/2024 04:38 PM*" y "*1711986720*"
F2	id_estacion	Inconsistencia de espacios en blanco adicionales y mezcla de mayúsculas y minúsculas en los identificadores	" *EST-001* " frente a "*est-001*"
F3	id_bus	Presencia de valores nulos o vacíos (NaN) debido a fallas intermitentes de transmisión telemática en campo	Campo vacío o nulo en el registro del bus asociado a la validación

3. Diagnóstico de madurez

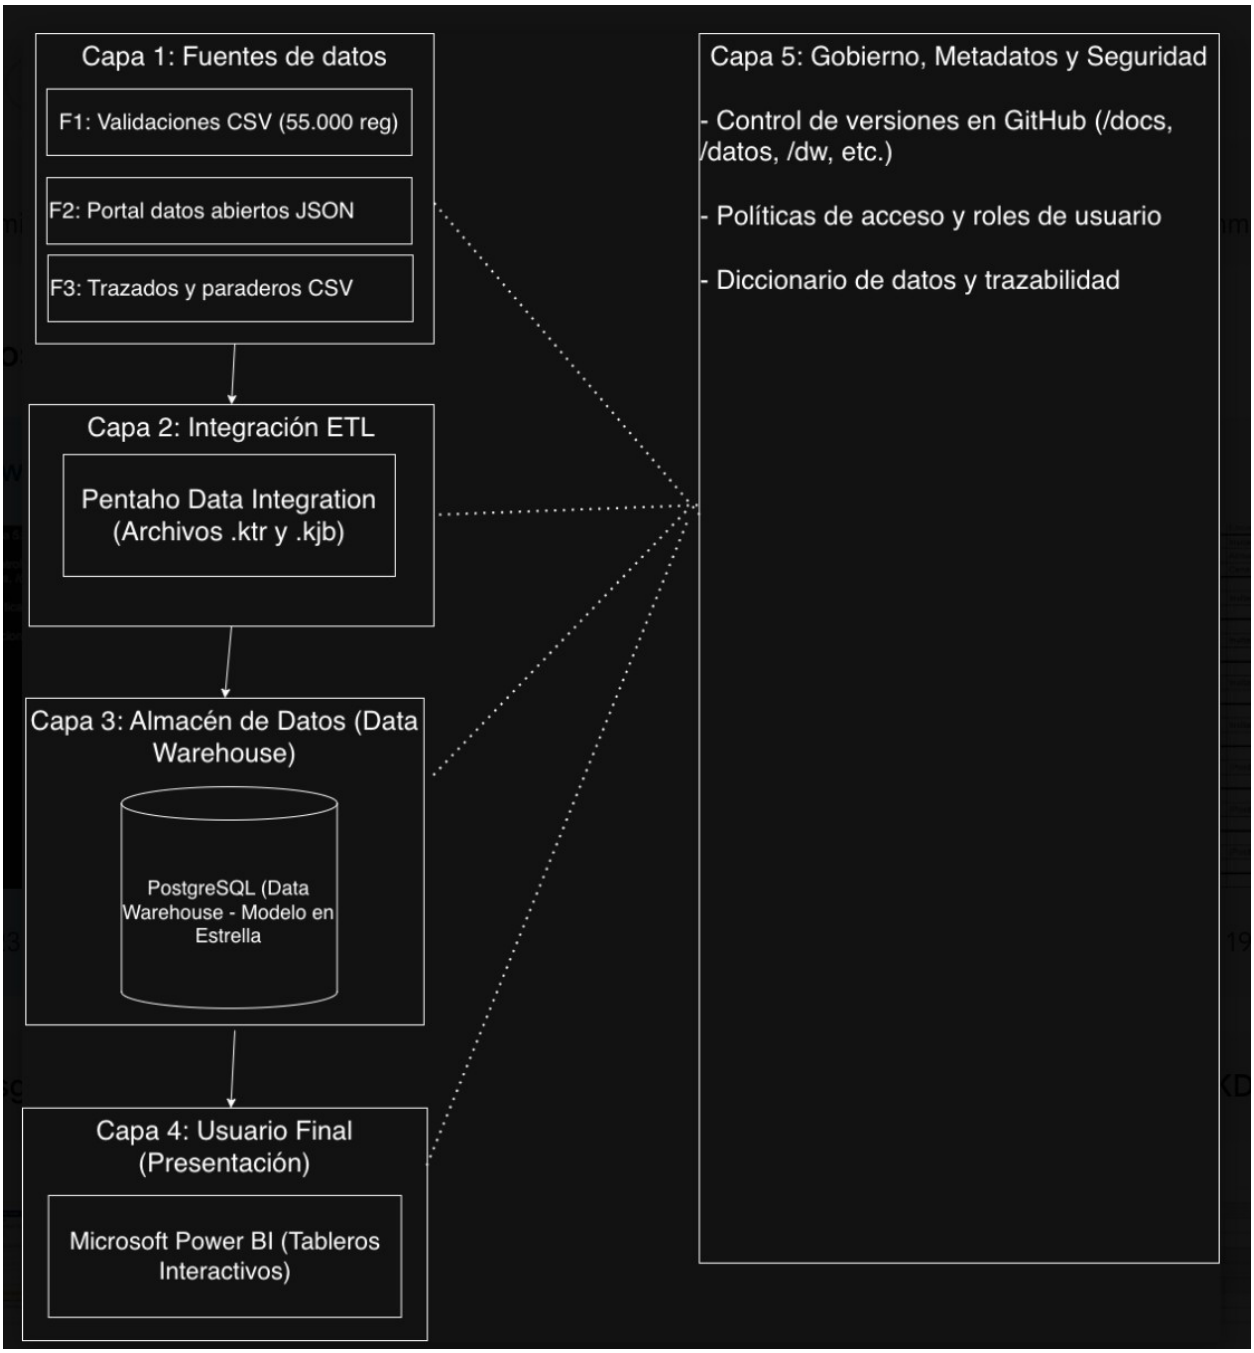
Elemento	Respuesta
Fase actual	1. No existe BI
Evidencia	Los síntomas S1, S2 y S3 demuestran que los datos están fragmentados en archivos heterogéneos, los reportes se construyen manualmente en hojas de cálculo y no existe un repositorio centralizado de información confiable
Por qué no es la fase siguiente	Para estar en la Fase 2 (Datos accesibles sin BI), la empresa debería contar al menos con un repositorio unificado o consultas directas a bases transaccionales limpias. Sin embargo, hoy los datos están aislados y requieren limpieza manual repetitiva
Fase objetivo al final del proyecto	4. Data Warehouse

Elemento	Respuesta
Brechas que cierra el proyecto	1. Implementación de un proceso ETL automatizado para unificar fuentes 2. Creación de un almacén de datos dimensional, una buena opción sería un esquema en estrella en PostgreSQL

4. Arquitectura

La arquitectura de Business Intelligence propuesta para MoviBogotá S.A. se estructura bajo un modelo de cinco capas integradas que garantiza la escalabilidad, la trazabilidad y el rendimiento en el procesamiento de los datos operativos de la flota. El flujo inicia en la Capa de Fuentes de Datos, consolidando las transacciones de validación de pasajeros (F1), el catálogo de estaciones y zonas del Portal de Datos Abiertos (F2) y los trazados de rutas (F3). Posterior a esto, la información es procesada, depurada y transformada mediante la Capa de Integración (ETL) utilizando Pentaho Data Integration (PDI), para ser cargada de manera estructurada en un Almacén de Datos (Data Warehouse) implementado en PostgreSQL bajo un modelo dimensional en estrella. Esta estructura alimenta la Capa de Usuario Final, donde se despliegan tableros interactivos en Microsoft Power BI orientados a la Gerencia de Operaciones para la toma de decisiones sobre frecuencias y asignación de flota. Todo este ecosistema se encuentra respaldado transversalmente por la Capa de Gobierno, Metadatos y Seguridad, gestionada a través de GitHub para el control de versiones, esquemas de seguridad de bases de datos y políticas de acceso basados en roles.

4.1 Diagrama de cinco capas del caso



4.2 Componentes por capa

Capa	Componentes y herramientas del caso	Función en el caso
1. Fuentes de datos	**F1** (CSV local Datased_registros.csv – 55.000 registros), **F2** (Portal Datos Abiertos JSON - Catálogo Zonal/Estaciones), **F3** (Trazados y paraderos CSV - 154 registros).	Aportar los datos operativos transaccionales de validaciones, la infraestructura de paraderos/estaciones y las rutas de MoviBogotá S.A.

Capa	Componentes y herramientas del caso	Función en el caso
2. Integración (ETL)	Pentaho Data Integration (PDI) (Archivos .ktr para transformaciones y .kjb para flujos/jobs).	Extraer los datos sintéticos y de catálogos, aplicar reglas de limpieza (tratar nulos, estandarizar fechas, corregir montos negativos) y cargarlos al almacén de datos.
3. Almacén de datos	PostgreSQL (Data Warehouse estructurado bajo un Modelo Dimensional en Estrella).	Centralizar y organizar la información en tablas de hechos (hech_validaciones) y dimensiones (dim_tiempo, dim_estacion, dim_ruta, dim_tarjeta).
4. Usuario final	Microsoft Power BI Desktop / Service (Dashboards y tableros interactivos).	Permitir al Gerente de Operaciones y Planeación del Servicio analizar frecuencias, horarios pico, demanda por ruta y optimizar el despacho de la flota.
5. Gobierno, metadatos, monitoreo y seguridad	GitHub (Repositorio para control de versiones en /docs, /datos, /dw, /etl), esquemas de seguridad de PostgreSQL y catálogos de metadatos.	Garantizar el control de versiones del proyecto, auditoría de código, trazabilidad de datos y gestión de permisos basados en roles (RBAC).

4.3 Marco de Referencia de cuatro categorías

Categoría	Decisión tomada	Justificación
Arquitectura de información	Definición de flujos de datos operativos desde las transacciones de validación hasta los indicadores clave de rendimiento (KPIs) de ocupación y tiempo de espera.	Permite responder a la pregunta de negocio bloqueada: reprogramación dinámica de flota y asignación de frecuencias para minimizar kilómetros en vacío.
Arquitectura de datos	Implementación de un modelo dimensional en estrella en PostgreSQL con una tabla de hechos central y 4 dimensiones.	Facilita consultas analíticas de alto rendimiento, agrega datos operativos por intervalos temporales y estandariza la granularidad transaccional.
Arquitectura técnica	Selección de stack open-source/estándar: Pentaho PDI (ETL), PostgreSQL (DW) y Power BI (Visualización).	Minimiza costos de licencias iniciales, garantiza interoperabilidad nativa entre capas y ofrece alta estabilidad para el volumen de +55.000 registros.
Arquitectura de producto	Despliegue de un tablero ejecutivo interactivo en Power BI accesible para la Gerencia de Operaciones.	Entrega visualizaciones accionables, mapas de calor por paradero y alertas de congestión para la toma de decisiones estratégicas de la flota.

4.4 Decisión de despliegue

Criterio	**On-premise**	**Opción cloud:** PaaS / SaaS (Azure Postgres + Power BI Cloud)	**Elegida y por qué**
Costo	Alto costo inicial en infraestructura física, servidores locales y mantenimiento continuo	Modelo de pago por uso (SaaS/PaaS) con bajo costo de entrada y sin inversión en hardware	**Cloud:** Reduce los costos fijos iniciales de MoviBogotá S.A. y escala los recursos según la demanda analítica
Seguridad y cumplimiento	Control total interno, pero requiere un equipo dedicado a parches, copias de seguridad y seguridad física	Cumplimiento normativo automatizado, cifrado en reposo y en tránsito, y backups automáticos	**Cloud:** Mantiene estándares internacionales de seguridad de datos sin sobrecargar al equipo interno de TI
Escalabilidad	Limitada al hardware adquirido. Ampliar capacidad requiere nuevos servidores e instalación manual	Escalabilidad elástica e inmediata para procesar grandes incrementos de volúmenes de datos	**Cloud:** Permite absorber el crecimiento futuro de transacciones de la flota (+450 buses) de manera transparente
Acceso móvil	Restringido a la red interna de la empresa o dependiente de configuraciones complejas de VPN	Acceso seguro desde cualquier lugar y dispositivo móvil a través de la app de Power BI Service.	**Cloud:** Permite al Gerente de Operaciones supervisar la flota y tomar decisiones desde terreno o en tiempo real.

5. Modelo dimensional

Se selecciona un Modelo en Estrella para el diseño del almacén de datos en PostgreSQL. Este modelo se compone de una tabla central de hechos (*hech_validaciones*) que almacena las métricas cuantitativas del negocio, rodeada por tablas de dimensiones independientes (*dim_tiempo*, *dim_estacion*, *dim_ruta*, *dim_tarjeta*)

Justificación: El modelo en estrella optimiza el rendimiento de las consultas analíticas complejas ejecutadas por el Gerente de Operaciones en Power BI, simplifica las uniones (joins) y permite agregar de forma eficiente el volumen de transacciones de la flota (+55.000 registros), facilitando la detección de cuellos de botella e indicadores de tiempos de espera.

5.1 Proceso de negocio

El proceso de negocio modelado corresponde a la operación de transporte público urbano y el registro de validaciones de pasajeros en la red de MoviBogotá S.A. Este proceso abarca desde que un usuario accede al sistema utilizando un medio de pago (tarjeta de validación) en una estación o paradero específico, hasta la generación de transacciones operativas diarias. El modelo centraliza estos eventos de validación para permitir a la Gerencia de Operaciones evaluar la demanda de pasajeros por franja horaria, correlacionarla

con el uso de las rutas y tomar decisiones informadas sobre la reprogramación dinámica de frecuencias y asignación de flota, minimizando los kilómetros en vacío y los tiempos de espera.

5.2 Granularidad

Una fila de la tabla de hechos representa:

Una transacción individual de validación de pasaje efectuada por un pasajero en una estación o paradero determinado, asociada a una ruta específica, en un momento temporal exacto y con un medio de pago registrado

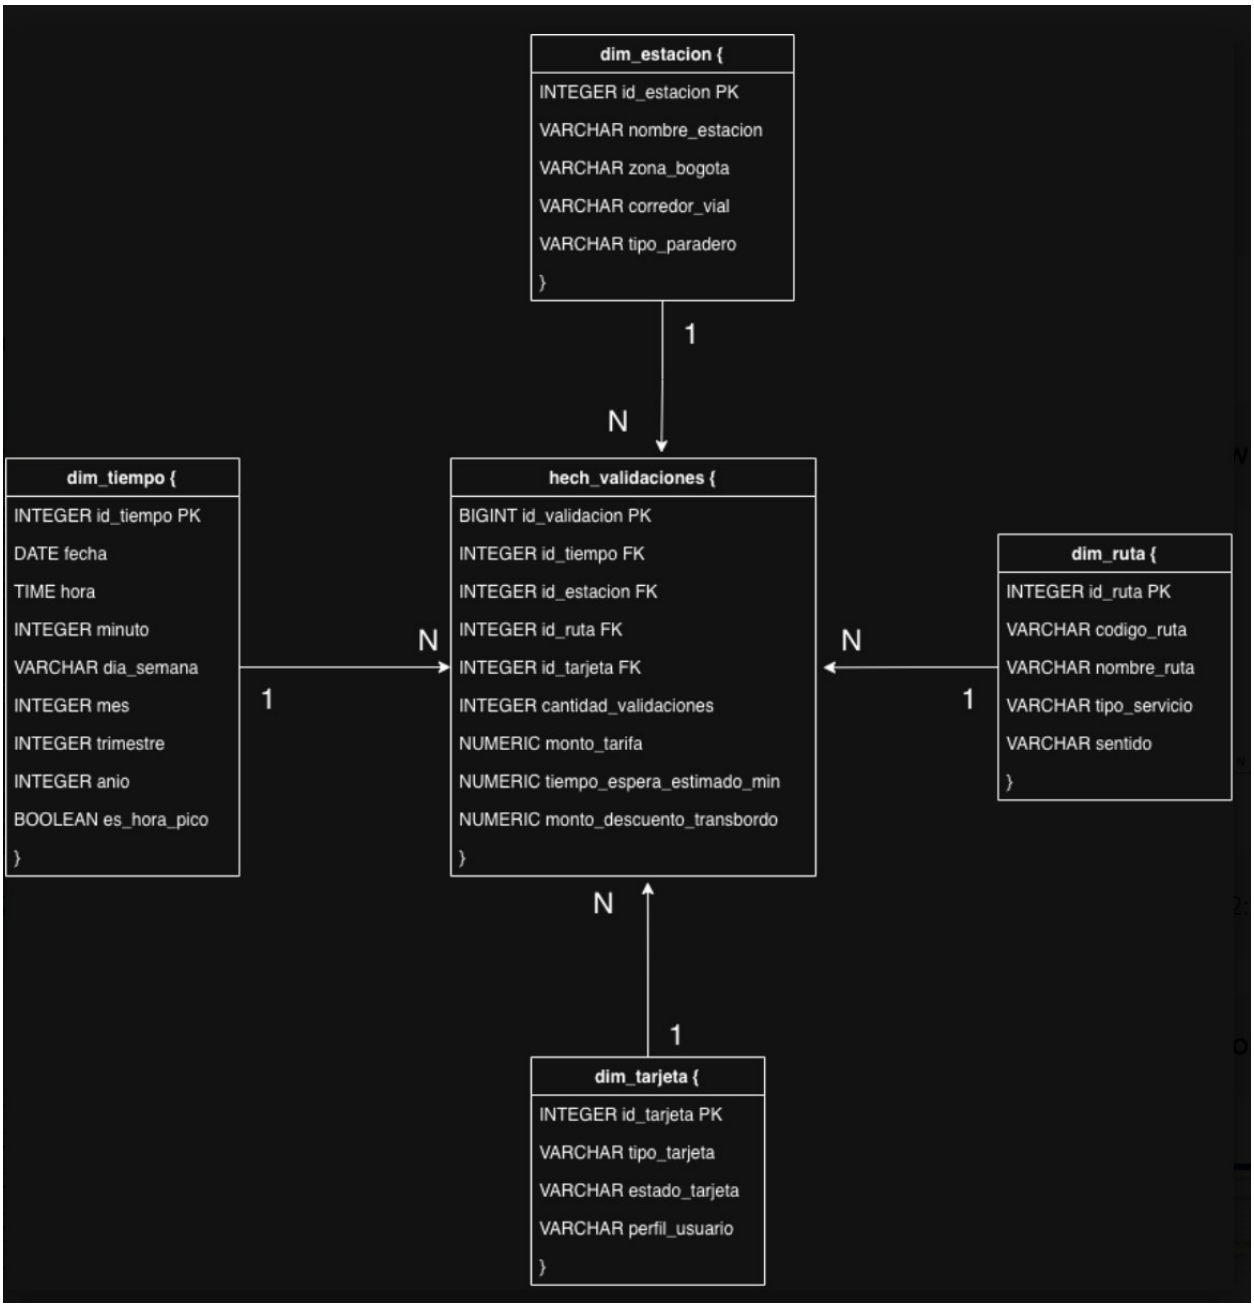
5.3 Métricas de la tabla de hechos

Métrica	Tipo de dato	Aditividad	Origen o fórmula
Cantidad_validaciones	Integer	Aditiva	Conteo de transacciones (COUNT(id_validacion) o valor constante 1 por fila de validación)
Monto_tarifa	Numeric (10,2)	Aditiva	Suma directa del valor cobrado al usuario en COP por pasaje (monto_tarifa)
tiempo_espera_estimado_min	Numeric (5,2)	No aditiva	Promedio del tiempo de espera calculado entre frecuencias de buses (AVG(intervalo_buses)).

5.4 Dimensiones

Dimensión	Atributos principales	Jerarquía	Fuente
Tiempo	id_tiempo, fecha, hora, minuto, dia_semana, mes, trimestre, anio, es_hora_pico	día -> mes -> trimestre -> año	Generada (Dimensión de calendario y hora)
Estacion/ Parada	id_estacion, nombre_estacion, zona_bogota, corredor_vial, tipo_paradero	Paradero -> zona_bogota -> corredor_vial	F2 (Portal Datos Abiertos)/F3
Ruta/Servicio	id_ruta, codigo_ruta, nombre_ruta, tipo_servicio, sentido	Código_ruta -> tipo_servicio	F3 (Catálogo de Rutas y Trazados
Tarjeta/Usuario	id_tarjeta, tipo_tarjeta, estado_tarjeta, perfil_usuario	N/A	F1 (Validaciones transaccionales)

5.5 Diagrama del esquema



Justificación sobre el uso del esquema de estrella: Se selecciona un esquema en estrella en lugar de un esquema de copo de nieve debido a la simplicidad y eficiencia superior que aporta para las consultas analíticas requeridas por la Gerencia de Operaciones. Al mantener las tablas dimensionales desnormalizadas (como *dim_estacion*, *dim_ruta*, *dim_tiempo y dim_tarjeta*), se reducen significativamente las operaciones de unión (*joins*) necesarias tanto en el motor de PostgreSQL como en los cálculos de Power BI. Esto optimiza de forma directa el rendimiento de los tableros interactivos para procesar el volumen operativo de transacciones de la flota, evitando la complejidad innecesaria y el impacto en el tiempo de respuesta que introduciría la fragmentación en múltiples sub-dimensiones propia del esquema de copo de nieve.

5.6 Trazabilidad con las preguntas

Pregunta	Métricas que usa	Dimensiones que usa
P0	cantidad_validaciones, monto_tarifa	dim_tiempo, dim_estacion, dim_ruta, dim_tarjeta
P1	cantidad_validaciones, tiempo_espera_estimado_min	dim_tiempo, dim_estacion, dim_ruta
P2	cantidad_validaciones, tiempo_espera_estimado_min	dim_tiempo, dim_ruta
P3	cantidad_validaciones, monto_descuento_transbordo	dim_tiempo, dim_tarjeta, dim_estacion

6. Referencias

Alcaldía Mayor de Bogotá. (2024). *Búsqueda de conjuntos de datos sobre transporte masivo*. Portal Nacional de Datos Abiertos de Colombia. https://www.datos.gov.co/browse?q=transporte+masivo+bogota&sortBy=relevance&page=1&pageSize=20

MoviBogotá S.A. (2025). *Registro transaccional sintético de validaciones y uso del sistema de transporte urbano (2024-2025)* [Conjunto de datos no publicado].

Secretaría Distrital de Movilidad. (2026). *Portal de datos abiertos de la Secretaría de Movilidad*. https://datos.movilidadbogota.gov.co/

TRANSMILENIO S.A. (2026). *Portal de datos abiertos - TransMilenio S.A.* https://datosabiertos-transmilenio.hub.arcgis.com/

Anexos

Anexo A. Diccionarios de datos

Campo	Tipo	Descripción	Ejemplo	Problema de calidad
id_validacion	INTEGER	Identificador único de la transacción de validación.	100245	Ninguno (Clave primaria limpia)
fecha_hora	VARCHAR / TIMESTAMP	Fecha y hora en que el usuario valida el pasaje	2024-10-15 07:32:10	**S1:** Formato inconsistente de fechas (DD/MM/YYYY vs YYYY-MM-DD).
id_estacion	INTEGER	Código de la estación o paradero donde ocurrió la validación	EST_045	**S2:** Presencia de valores nulos/vacíos en transacciones de buses zonales.
id_ruta	VARCHAR	Código identificador de la ruta del bus	F14	Ninguno
id_tarjeta	VARCHAR	Código encriptado del medio de pago utilizado	TJ_998341	Ninguno
monto_tarifa	NUMERIC	Valor cobrado por la validación	2.950	**S4:** Registros aislados con montos negativos o valores atípicos de cero.

Diccionario de datos – Fuente F2: Portal Datos Abiertos (Catálogo Zonal y Estaciones)

Campo	Tipo	Descripción	Ejemplo	Problema de calidad
codigo_estacion	VARCHAR	Identificador único oficial de la estación o paradero	EST_045	Ninguno
nombre_estacion	VARCHAR	Nombre público de la estación o portal	Portal Norte	Inconsistencias menores en caracteres especiales/acentos
zona	VARCHAR	Zona geográfica de planificación dentro de Bogotá	Suba	Ninguno
corredor_vial	VARCHAR	Troncal o avenida principal asociada	AutoNorte	Nulos en paraderos zonales de calles secundarias

Diccionario de Datos — Fuente F3: Trazados y Paraderos Troncales

Campo	Tipo	Descripción	Ejemplo	Problema de calidad
id_ruta	VARCHAR	Identificador único de la línea o ruta de bus.	F/C19	Ninguno
nombre_ruta	VARCHAR	Origen y destino de la ruta.	Portal Suba - Portal Américas	Ninguno
tipo_servicio	VARCHAR	Clasificación del servicio (Troncal, Alimentador, Zonal).	Troncal	Ninguno
sentido	VARCHAR	Orientación del recorrido (Norte-Sur, Sur-Norte).	Norte-Sur	Abrevaturas heterogéneas (N-S, Norte-Sur)

Anexo B. Diagramas a tamaño completo

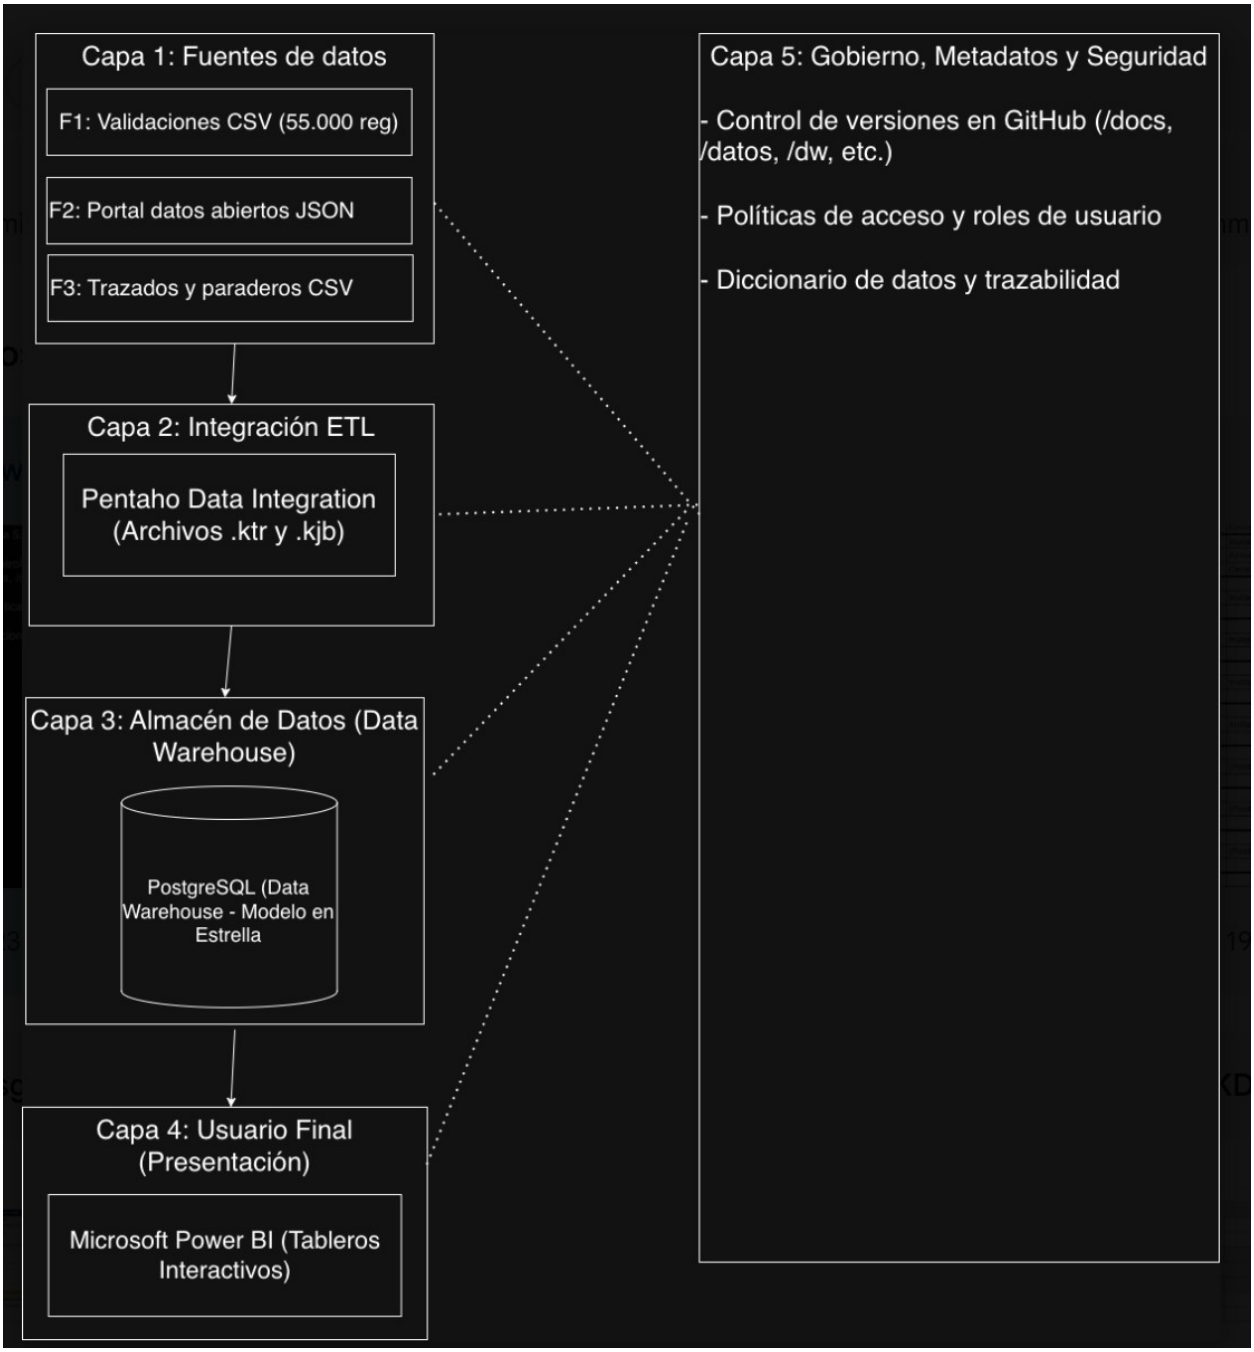


Figura B1. Arquitectura de Business Intelligence de cinco capas para MoviBogotá S.A.

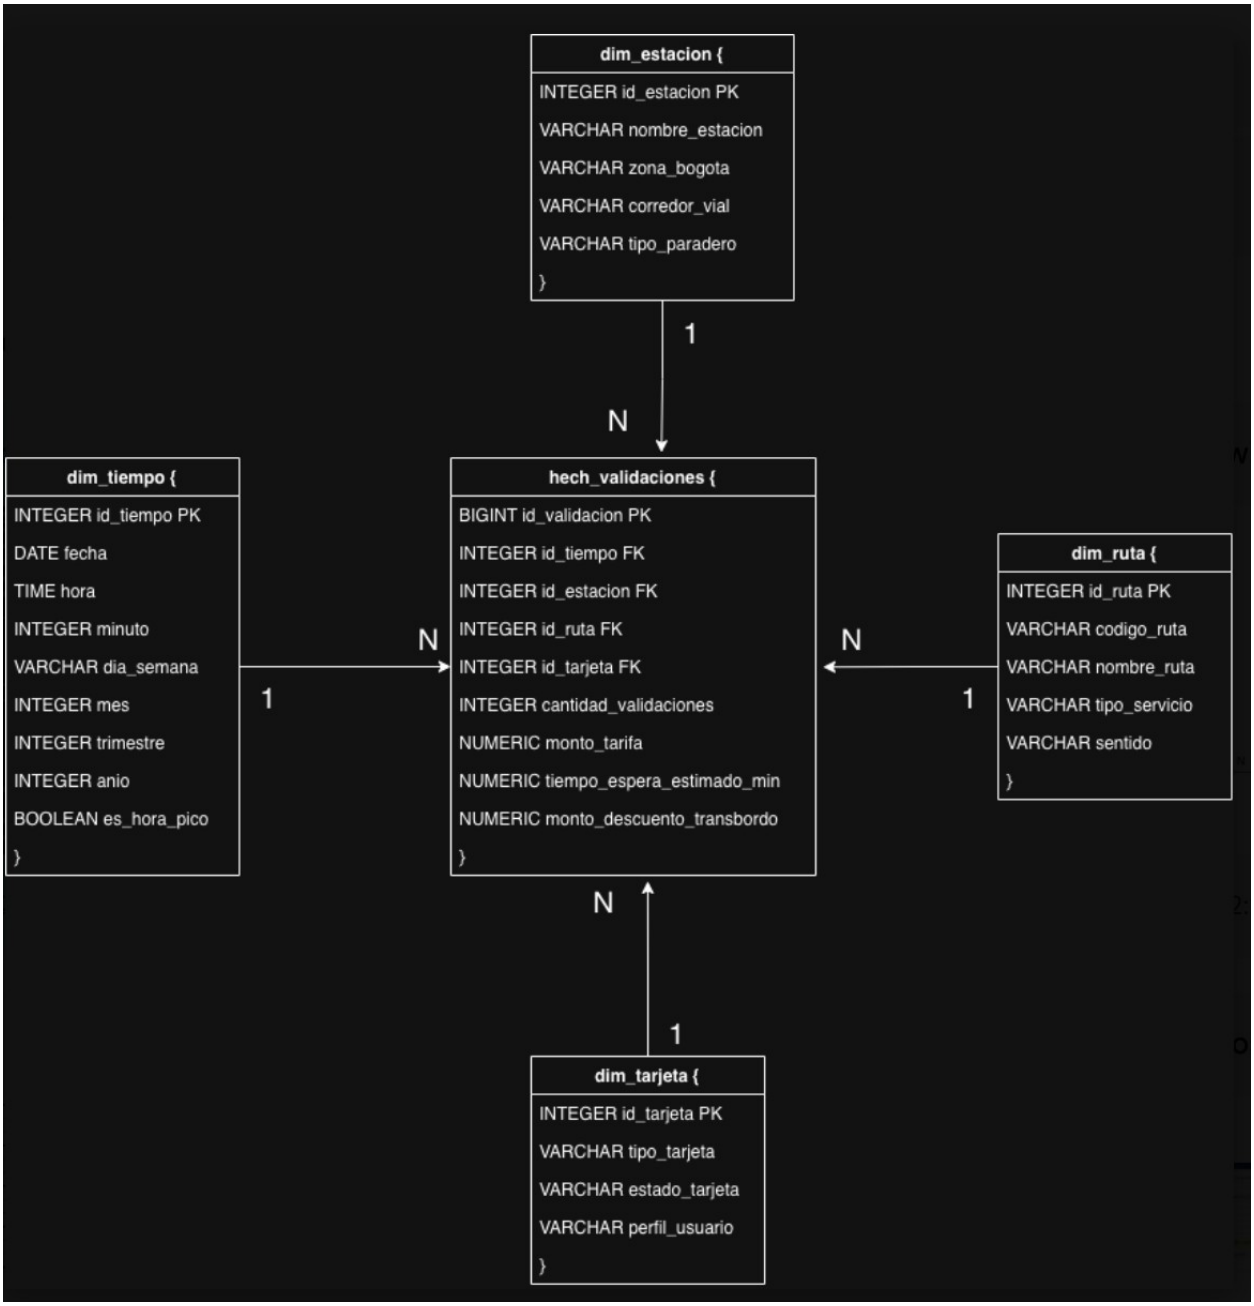


Figura B2. Diagrama del Esquema Dimensional en Estrella